

## Statistique descriptive bivariée

Couple de variables

M. Mellouk

# Objectifs

- **Statistique univariée** : analyse descriptive séparée de chaque variable d'un tableau *individus* × *variables*.
- **Statistique bivariée** : analyse descriptive des variables deux à deux :
  - étude d'un couple de variables statistiques
  - étude de la liaison entre deux variables quantitatives, qualitatives, quantitative/qualitative
  - **étape indispensable de toute analyse de jeux de données : croisement systématique des variables 2 à 2.**
- Statistique descriptive multivariée : Analyse des données.

# Données brutes et données groupées

Étude de deux variables  $X$  et  $Y$  sur une **même population** de taille  $n$  :

- $x_k$  et  $y_k$  : valeurs prises par  $X$  et  $Y$  pour un même individu  $k$ ,  
 $1 \leq k \leq n$ .
- **Données brutes**  $(x_k, y_k)_{k=1, \dots, n}$  : les  $n$  couples d'observations

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

# Exemple

Extrait des données brutes :

Individu	Sexe X	Salaire horaire Y
1	F	13.25
2	F	12.50
3	H	14.00
4	F	13.00
5	H	7.00
6	F	29.80
...		
599	H	14.50

- Le salaire horaire dépend-il du sexe des individus ?

# Exemple

Extrait des données brutes :

Employé	Catégorie de personnel	Age	Région
1	A	58	NE
2	B	42	W
3	A	35	S
4	B	26	NE
5	B	22	W
6	C	32	NW
7	A	42	NE
...	...	...	...
597	C	41	S
598	C	33	NW
599	C	29	S

- La répartition des âges est-elle différente selon la catégorie de personnel (et dans quelle mesure) ?
- La catégorie des employés est-elle liée à la région (et de quelle manière) ?

# Extrait des données

```
> head(Donnees)
{\small
  AGE SEXE REGION STAT_MARI SAL_HOR SYNDICAT CATEGORIE NIV_ETUDES NB_PERS NB_ENF REV_FOYER
1 58   F    NE      C  13.25   non       5     43      2      0     11
2 40   M    W      M  12.50   non       7     38      2      0      7
3 29   M    S      C  14.00   non       5     42      2      0     15
4 59   M    NE     D  10.60   oui       3     39      4      1      7
5 51   M    W      M  13.00   non       3     35      8      1     15
6 19   M    NW     C   7.00   non       3     39      6      0     16
}

> tail(Donnees)

  AGE SEXE REGION STAT_MARI SAL_HOR SYNDICAT CATEGORIE NIV_ETUDES NB_PERS NB_ENF REV_FOYER
594 63   M    NE      M  10.5    non       4     40      2      0     13
595 51   F    S      M  29.8    non       2     42      2      0     14
596 29   F    NE     C  27.0    oui       1     43      2      0     15
597 57   F    NW     D  21.0    non       4     40      1      0     14
598 29   F    W      M  13.0    oui       5     39      6      4     11
599 47   M    S      C  14.5    non       4     39      1      0     12
}
```

# Description des données

```
> dim(Donnees)
[1] 599 11

> attach(Donnees)

> names(Donnees)
[1] "AGE"    "SEXE"   "REGION"  "STAT_MARI" "SAL_HOR"  "SYNDICAT" "CATEGORIE" "NIV_ETUDES"
[9] "NB_PERS" "NB_ENF"  "REV_FOYER"

> str(Donnees)

'data.frame': 599 obs. of 11 variables:
 $ AGE      : int  58 40 29 59 51 19 64 23 47 66 ...
 $ SEXE     : Factor w/ 2 levels "F","M": 1 2 2 2 2 2 1 1 2 1 ...
 $ REGION   : Factor w/ 4 levels "NE","NW","S",...: 1 4 3 1 4 2 3 1 2 3 ...
 $ STAT_MARI: Factor w/ 5 levels "C","D","M","S",...: 1 3 1 2 3 1 3 1 3 2 ...
 $ SAL_HOR  : num  13.2 12.5 14 10.6 13 ...
 $ SYNDICAT : Factor w/ 2 levels "non","oui": 1 1 1 2 1 1 1 1 2 1 ...
 $ CATEGORIE: int  5 7 5 3 3 3 9 1 8 5 ...
 $ NIV_ETUDES: int  43 38 42 39 35 39 40 43 40 40 ...
 $ NB_PERS   : int  2 2 2 4 8 6 3 2 3 1 ...
 $ NB_ENF    : int  0 0 0 1 1 0 0 0 0 0 ...
 $ REV_FOYER : int  11 7 15 7 15 16 13 11 12 8 ...
```

# Description des données

```
## Modification du type des variables

Donnees$CATEGORIE=as.factor(Donnees$CATEGORIE)
Donnees$NIV_ETUDES=as.factor(Donnees$NIV_ETUDES)
Donnees$REV_FOYER=as.factor(Donnees$REV_FOYER)

> str(Donnees)

'data.frame': 599 obs. of 11 variables:
 $ AGE      : int  58 40 29 59 51 19 64 23 47 66 ...
 $ SEXE     : Factor w/ 2 levels "F","M": 1 2 2 2 2 2 1 1 2 1 ...
 $ REGION   : Factor w/ 4 levels "NE","NW","S",...: 1 4 3 1 4 2 3 1 2 3 ...
 $ STAT_MARI : Factor w/ 4 levels "C","D","M","V": 1 3 1 2 3 1 3 1 3 2 ...
 $ SAL_HOR   : num  13.2 12.5 14 10.6 13 ...
 $ SYNDICAT : Factor w/ 2 levels "non","oui": 1 1 1 2 1 1 1 1 2 1 ...
 $ CATEGORIE : Factor w/ 10 levels "1","2","3","4",...: 5 7 5 3 3 3 9 1 8 5 ...
 $ NIV_ETUDES: Factor w/ 15 levels "32","33","34",...: 12 7 11 8 4 8 9 12 9 9 ...
 $ NB_PERS   : int  2 2 2 4 8 6 3 2 3 1 ...
 $ NB_ENF    : int  0 0 0 1 1 0 0 0 0 ...
 $ REV_FOYER : Factor w/ 16 levels "1","2","3","4",...: 11 7 15 7 15 16 13 11 12 8 ...
```

# Résumé des données

```
> summary(Donnees)
```

AGE	SEXE	REGION	STAT_MARI	SAL_HOR	SYNDICAT	CATEGORIE	NIV_ETUDES
Min. :16.00	F:297	NE:129	C:193	Min. : 2.0	non:496	2 :133	39 :187
1st Qu.:29.00	M:302	NW:122	D: 75	1st Qu.:10.5	oui:103	3 :125	40 :148
Median :42.00		S :200	M:325	Median :15.0		5 : 94	43 :114
Mean :41.85		W :148	V: 6	Mean :17.9		4 : 48	42 : 45
3rd Qu.:53.50				3rd Qu.:22.0		1 : 46	44 : 29
Max. :80.00				Max. :99.0		9 : 39	41 : 22
					(Other):114	(Other): 54	

NB_PERS	NB_ENF	REV_FOYER
Min. : 1.00	Min. :0.0000	14 : 89
1st Qu.: 2.00	1st Qu.:0.0000	15 : 77
Median : 3.00	Median :0.0000	13 : 71
Mean : 3.11	Mean :0.5326	12 : 70
3rd Qu.: 4.00	3rd Qu.:1.0000	11 : 61
Max. :13.00	Max. :6.0000	16 : 48
		(Other):183

# X et/ou Y qualitatives ou quantitatives discrètes

- $x_1, x_2, \dots, x_i, \dots, x_p$  : les  $p$  modalités de  $X$  ( $p$  observations distinctes de  $X$ )
- $y_1, y_2, \dots, y_j, \dots, y_q$  : les  $q$  modalités de  $Y$  ( $q$  observations distinctes de  $Y$ )

# X et/ou Y quantitatives continues

- Valeurs de X regroupées en  $p$  classes

$$[e_0^X, e_1^X[, \dots, [e_{i-1}^X, e_i^X[, \dots, [e_{p-1}^X, e_p^X[$$

de centres  $x_1, \dots, x_i, \dots, x_p$

- Valeurs de Y en  $q$  classes

$$[e_0^Y, e_1^Y[, \dots, [e_{j-1}^Y, e_j^Y[, \dots, [e_{q-1}^Y, e_q^Y[$$

de centres  $y_1, \dots, y_j, \dots, y_q$

- Confusion parfois entre la classe  $[e_{i-1}^X, e_i^X[$  et son centre  $x_i$

## Données groupées

- $n_{ij}$  : nombre d'individus pour lesquels à la fois  $X$  prend la valeur  $x_i$  **et**  $Y$  la valeur  $y_j$

$$n_{ij} = \#\{k = 1, \dots, n \mid x_k = x_i \text{ et } y_k = y_j\}$$

- Si  $X$  est continue,  $x_k = x_i$  signifie  $x_k \in [e_{i-1}^X, e_i^X[$  de centre  $x_i$
- **Données groupées** :  $(x_i, y_j, n_{ij})_{i=1, \dots, p, j=1, \dots, q}$

# Tableaux statistiques et distribution d'une série bivariée

## Distribution jointe - Tableau de contingence

- **Distribution jointe en effectifs** de  $X$  et de  $Y$  :

$$\{(x_i, y_j, n_{ij}) ; 1 \leq i \leq p, 1 \leq j \leq q\}$$

- Pour  $i = 1, \dots, p$  et  $j = 1, \dots, q$ 
  - $n_{ij}$  : nombre d'individus possédant la modalité  $x_i$  de  $X$  **et** la modalité  $y_j$  de  $Y$ .
  - $n_{i\bullet} = \sum_{j=1}^q n_{ij}$  : nombre d'individus possèdent la modalité  $x_i$  ( $\in$  classe de centre  $x_i$ ) de  $X$
  - $n_{\bullet j} = \sum_{i=1}^p n_{ij}$  : nombre d'individus possèdent la modalité  $y_j$  de  $Y$
  - $n = \sum_{i=1}^p \sum_{j=1}^q n_{ij} = \sum_{i=1}^p n_{i\bullet} = \sum_{j=1}^q n_{\bullet j}$ ; nombre total d'individus de la population.

# Tableau de contingence en effectifs ( $p$ lignes, $q$ colonnes)

$X$	$Y$	$y_1$	$y_2$	$\dots$	$y_j$	$\dots$	$y_q$	Total
$x_1$		$n_{11}$	$n_{12}$	$\dots$	$n_{1j}$	$\dots$	$n_{1q}$	$n_{1\bullet}$
$x_2$		$n_{21}$	$n_{22}$	$\dots$	$n_{2j}$	$\dots$	$n_{2q}$	$n_{2\bullet}$
$\vdots$		$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
$x_i$		$n_{i1}$	$n_{i2}$	$\dots$	$n_{ij}$	$\dots$	$n_{iq}$	$n_{i\bullet}$
$\vdots$		$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
$x_p$		$n_{p1}$	$n_{p2}$	$\dots$	$n_{pj}$	$\dots$	$n_{pq}$	$n_{p\bullet}$
Total		$n_{\bullet 1}$	$n_{\bullet 2}$	$\dots$	$n_{\bullet j}$	$\dots$	$n_{\bullet q}$	$n$

## Tableau de contingence : SEXE x REGION

```
> TabContEf<-table(SEXE,REGION)
> print(TabContEf) # affiche le nom des variables
```

REGION

SEXE	NE	NW	S	W
F	61	62	97	77
M	68	60	103	71

```
> addmargins(TabContEf)
```

REGION

SEXE	NE	NW	S	W	Sum
F	61	62	97	77	297
M	68	60	103	71	302
Sum	129	122	200	148	599

# X : SEXE et Y : REGION

- X de type ..... à  $p = \dots$  modalités.
- Y de type ..... 0  $q = \dots$  modalités.
- Mesures conjointes de X et Y sur  $n = \dots$  individus.

# Distribution jointe en fréquences

- Pour  $i = 1, \dots, p$  et  $j = 1, \dots, q$

- $f_{ij} = \frac{n_{ij}}{n}$  : proportion d'individus possédant la modalité  $x_i$  de la variable  $X$  **et** la modalité  $y_j$  de la variable  $Y$ .
- $f_{i\bullet} = \sum_{j=1}^q f_{ij}$  : fréquence de la modalité  $x_i$  de  $X$
- $f_{\bullet j} = \sum_{i=1}^p f_{ij}$  : fréquence de la modalité  $y_j$  de  $Y$
- $1 = \sum_{i=1}^p \sum_{j=1}^q f_{ij} = \sum_{i=1}^p f_{i\bullet} = \sum_{j=1}^q f_{\bullet j}$

- **Distribution jointe en fréquences** de  $X$  et de  $Y$  :

$$\{(x_i, y_j, f_{ij}) ; 1 \leq i \leq p, 1 \leq j \leq q\}$$

# Tableau de contingence en fréquences ( $p$ lignes, $q$ colonnes)

$X$	$Y$	$y_1$	$y_2$	$\dots$	$y_j$	$\dots$	$y_q$	Total
$x_1$		$f_{11}$	$f_{12}$	$\dots$	$f_{1j}$	$\dots$	$f_{1q}$	$f_{1\bullet}$
$x_2$		$f_{21}$	$f_{22}$	$\dots$	$f_{2j}$	$\dots$	$f_{2q}$	$f_{2\bullet}$
$\vdots$		$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
$x_i$		$f_{i1}$	$f_{i2}$	$\dots$	$f_{ij}$	$\dots$	$f_{iq}$	$f_{i\bullet}$
$\vdots$		$\vdots$	$\vdots$		$\vdots$		$\vdots$	$\vdots$
$x_p$		$f_{p1}$	$f_{p2}$	$\dots$	$f_{pj}$	$\dots$	$f_{pq}$	$f_{p\bullet}$
Total		$f_{\bullet 1}$	$f_{\bullet 2}$	$\dots$	$f_{\bullet j}$	$\dots$	$f_{\bullet q}$	1

# Tableau de contingence : SEXE x REGION

```
> TabContFr<-prop.table(TabContEf)
> print(TabContFr)
```

```
          REGION
SEXE      NE      NW      S      W
  F 0.1018364 0.1035058 0.1619366 0.1285476
  M 0.1135225 0.1001669 0.1719533 0.1185309
```

```
> print(round(TabContFr,2))
```

```
          REGION
SEXE    NE    NW    S    W
  F 0.10 0.10 0.16 0.13
  M 0.11 0.10 0.17 0.12
```

```
> addmargins(round(TabContFr,2))
```

```
          REGION
SEXE    NE    NW    S    W  Sum
  F    0.10 0.10 0.16 0.13 0.49
  M    0.11 0.10 0.17 0.12 0.50
  Sum 0.21 0.20 0.33 0.25 0.99
```

# Tableau de contingence en % : SEXE x REGION

```
> TabContPr<-100*prop.table(TabContEf)
> print(TabContPr)
      REGION
SEXE      NE      NW      S      W
  F 10.18364 10.35058 16.19366 12.85476
  M 11.35225 10.01669 17.19533 11.85309
> print(round(TabContPr,2))
      REGION
SEXE      NE      NW      S      W
  F 10.18 10.35 16.19 12.85
  M 11.35 10.02 17.20 11.85
> addmargins(round(TabContPr,2))
      REGION
SEXE      NE      NW      S      W   Sum
  F    10.18 10.35 16.19 12.85 49.57
  M    11.35 10.02 17.20 11.85 50.42
  Sum 21.53 20.37 33.39 24.70 99.99
```


# Tableau de contingence : Autre représentation

```
> library(gplots)  
> balloonplot(t(TabContEf), dotsizes=10, main="")
```




# Représentations graphiques

```
> N1=nlevels(SEXE) # nombre de modalites (niveaux) du facteur Sexe  
> N2=nlevels(REGION) # nombre de modalites (niveaux) du facteur REGION  
> couleurs=rainbow(N1)  
> barplot(TabContFr, col=couleurs,2)  
> legend("topleft", legend=c("F", "H"), col=couleurs,pch=15)
```



# Représentations graphiques


```
> barplot(TabContFr,beside=TRUE, col=couleurs, 2)
> legend("topleft", legend=c("F", "H"), col=couleurs,pch=15)
```



# Représentations graphiques

A ne pas faire (sauf si les modalités sont équilibrées) !

```
> couleurs=rainbow(N2)
> mosaicplot(TabContEf,col=couleurs,main="")
```



# Tableau de contingence : SEXE x SALAIRE

⇒ Tableau de contingence Qualitatif x Quantitatif.

```
> Nclasse=4 # Nombre de classes
> SALAIRE<-cut(SAL_HOR, breaks=Nclasse)
> TabContEf<-table(SEXE,SALAIRE)

> print(TabContEf)
      SALAIRE
SEXE (1.9,26.2] (26.2,50.5] (50.5,74.8] (74.8,99.1]
    F        262          31           3           1
    M        244          49           7           2

> addmargins(TabContEf)
      SALAIRE
SEXE (1.9,26.2] (26.2,50.5] (50.5,74.8] (74.8,99.1] Sum
    F        262          31           3       1 297
    M        244          49           7       2 302
    Sum      506          80           10      3 599
```

# Tableau de contingence : SEXE x SALAIRE

```
> TabContFr<-prop.table(TabContEf)


> print(TabContFr)
    SALAIRE
SEXE (1.9,26.2] (26.2,50.5] (50.5,74.8] (74.8,99.1]
      F 0.437395659 0.051752922 0.005008347 0.001669449
      M 0.407345576 0.081803005 0.011686144 0.003338898

> print(round(TabContFr,2))
    SALAIRE
SEXE (1.9,26.2] (26.2,50.5] (50.5,74.8] (74.8,99.1]
      F      0.44      0.05      0.01      0.00
      M      0.41      0.08      0.01      0.00

> addmargins(round(TabContFr,2))
    SALAIRE
SEXE (1.9,26.2] (26.2,50.5] (50.5,74.8] (74.8,99.1] Sum
      F      0.44      0.05      0.01      0.00  0.50
      M      0.41      0.08      0.01      0.00  0.50
      Sum     0.85      0.13      0.02      0.00  1.00
```

# Tableau de contingence : Autre représentation


```
> balloonplot(t(TabContEf), dotsizes=10, main="")
```



# Représentations graphiques


A ne pas faire (sauf si les modalités sont équilibrées) !

```
> couleurs=rainbow(N2)  
> mosaicplot(TabContEf,col=couleurs,main="")
```



# Représentations graphiques

```
> boxplot(SAL_HOR ~ SEXE,xlab="Sexe",ylab="SALAIRE")  
> abline(h=mean(SAL_HOR,na.rm=T),lty=2,col="red",lwd=2)
```



# Tableau de contingence : AGE x SALAIRE

⇒ Tableau de contingence Quantitatif x Quantitatif.

Salaire	âge (ans) horaire	[16 ;32[	[32 ;48[	[48 ;64[	[64 ;80]	Total
[2 ;26[	180	156	144	26	506	
[26 ;50[	11	28	40	1	80	
[50 ;76[	0	5	4	1	10	
[76 ;100]	1	0	1	1	3	
Total	192	189	189	29		599

- $X$  ..... à  $p = \dots$  classes.
- $Y$  ..... à  $q = \dots$  classes.
- Mesures conjointes de  $X$  et  $Y$  sur  $n = \dots$  individus.
- **4** .....

# Tableau de contingence : AGE x SALAIRE

```
> NclasseS=4 # Nombre de classes : Salaire
> SALAIRE<-cut(SAL_HOR,breaks=NclasseS)
> NclasseA=4 # Nombre de classes : Age
> Age<-cut(AGE,breaks=NclasseA)
> TabContEf<-table(Age,SALAIRE)    # Tableau de contingence : Effectif
> print(TabContEf)
```

## SALAIRE

Age	(1.9,26.2]	(26.2,50.5]	(50.5,74.8]	(74.8,99.1]	
(15.9,32]	180	11	0	1	
(32,48]	156	28	5	0	
(48,64]	144	40	4	1	
(64,80.1]	26	1	1	1	

```
> addmargins(TabContEf)
```

## SALAIRE


Age	(1.9,26.2]	(26.2,50.5]	(50.5,74.8]	(74.8,99.1]	Sum
(15.9,32]	180	11	0	1	192
(32,48]	156	28	5	0	189
(48,64]	144	40	4	1	189
(64,80.1]	26	1	1	1	29
Sum	506	80	10	3	599

# Tableau de contingence : AGE x SALAIRE

```
> TabContFr<-prop.table(TabContEf)      # Tableau de contingence : Fréquence  
  
> print(round(TabContFr,2))  
          SALAIRE  
Age        (1.9,26.2] (26.2,50.5] (50.5,74.8] (74.8,99.1]  
(15.9,32]      0.30       0.02       0.00       0.00  
(32,48]       0.26       0.05       0.01       0.00  
(48,64]       0.24       0.07       0.01       0.00  
(64,80.1]     0.04       0.00       0.00       0.00  
  
> addmargins(round(TabContFr,2))  
          SALAIRE  
Age        (1.9,26.2] (26.2,50.5] (50.5,74.8] (74.8,99.1]   Sum  
(15.9,32]      0.30       0.02       0.00       0.00  0.32  
(32,48]       0.26       0.05       0.01       0.00  0.32  
(48,64]       0.24       0.07       0.01       0.00  0.32  
(64,80.1]     0.04       0.00       0.00       0.00  0.04  
Sum           0.84       0.14       0.02       0.00  1.00
```

## Représentation graphique plus appropriée

```
> plot(AGE,SAL_HOR,pch=20,xlab="Age",ylab="Salaire horaire",main="")
```



## Distributions marginales

- **Distribution marginale de  $X$  en effectifs et en fréquences**

$$\{(x_i, n_{i\bullet}) ; 1 \leq i \leq p\} \quad \{(x_i, f_{i\bullet}) ; 1 \leq i \leq p\}$$

⇒ Dernière colonne du tableau de contingence en effectifs ou fréquences

- **Distribution marginale de  $Y$  en effectifs et en fréquences**

$$\{(y_j, n_{\bullet j}) ; 1 \leq j \leq q\} \quad \{(y_j, f_{\bullet j}) ; 1 \leq j \leq q\}$$

⇒ Dernière ligne du tableau de contingence en effectifs ou fréquences

# Tableaux des effectifs/fréquences de $X$ et de $Y$

$X$	effectif	fréquence
$x_1$	$n_{1\bullet}$	$f_{1\bullet}$
$x_2$	$n_{2\bullet}$	$f_{2\bullet}$
$\vdots$	$\vdots$	$\vdots$
$x_i$	$n_{i\bullet}$	$f_{i\bullet}$
$\vdots$	$\vdots$	$\vdots$
$x_p$	$n_{p\bullet}$	$f_{p\bullet}$
Total	$n = \sum_{i=1}^p n_{i\bullet}$	1

Dist. marginale de  $X$   
en eff. et en fréq.

$Y$	effectif	fréquence
$y_1$	$n_{\bullet 1}$	$f_{\bullet 1}$
$y_2$	$n_{\bullet 2}$	$f_{\bullet 2}$
$\vdots$	$\vdots$	$\vdots$
$y_j$	$n_{\bullet j}$	$f_{\bullet j}$
$\vdots$	$\vdots$	$\vdots$
$y_q$	$n_{\bullet q}$	$f_{\bullet q}$
Total	$n = \sum_{j=1}^q n_{\bullet j}$	1

Dist. marginale de  $Y$   
en eff. et en fréq.

# Distributions marginales : SEXE et REGION

$Y$	WE	NW	S	W	Total
Sexe $X$					
Femme	61	62	97	77	297
Homme	68	60	103	71	302
Total	129	122	200	148	599

```
> margin.table(TabContEf, 1)
```

SEXE

F	M
297	302

```
> margin.table(TabContEf, 2)
```

REGION

NE	NW	S	W
129	122	200	148

# Distributions marginales : SEXE et REGION

$Y$ Sexe $X$	WE	NW	S	W	Total
Femme	0.1018	0.1035	0.1619	0.1285	0.495
Homme	0.1135	0.1002	0.1720	0.1185	0.504
Total	0.215	0.203	0.333	0.247	1

```
> margin.table(TabContFr, 1)
```

SEXE

F	M
0.4958264	0.5041736

```
> margin.table(TabContFr, 2)
```

REGION

NE	NW	S	W
0.215	0.203	0.333	0.247

## Distributions conditionnelles

- Distributions conditionnelles de  $X$  sachant  $Y$  (colonne fixée) et de  $Y$  sachant  $X$  (ligne fixée)
- En effectifs, pour tout  $i = 1, \dots, p$  et  $j = 1, \dots, q$ 
  - $n_{ij}$  : nombre d'individus tq  $X = x_i$  **et**  $Y = y_j$
  - $n_{i/j}$  : nombre d'individus tq  $X = x_i$  **parmi** ceux pour lesquels  $Y = y_j$

$$n_{i/j} = n_{ij} \quad \text{avec } j \text{ fixé}$$

- $n_{j/i}$  : nombre d'individus tq  $Y = y_j$  **parmi** ceux pour lesquels  $X = x_i$

$$n_{j/i} = n_{ij}, \quad i \text{ fixé}$$

- En fréquences, pour tout  $i = 1, \dots, p$  et  $j = 1, \dots, q$ ,

- $f_{ij}$  : proportion d'individus tq  $X = x_i$  **et**  $Y = y_j$
- $f_{i/j}$  : proportion d'individus pour lesquels  $X = x_i$  **parmi** ceux pour lesquels  $Y = y_j$ .

$$f_{i/j} = \frac{n_{ij}}{n_{\bullet j}}$$

- $f_{j/i}$  : proportion d'individus pour lesquels  $Y = y_j$  **parmi** ceux pour lesquels  $X = x_i$

$$f_{j/i} = \frac{n_{ij}}{n_{i\bullet}}$$

# Distributions conditionnelles en effectifs et fréquences

- **Distribution conditionnelle en effectifs de  $X$  sachant  $Y = y_j$**

$$\{(x_i, n_{i/j}) ; 1 \leq i \leq p, j \text{ fixé}\}$$

( $j^{\text{ème}}$  colonne du tableau de contingence en effectifs)

- **Distribution conditionnelle en effectifs de  $Y$  sachant  $X = x_i$**

$$\{(y_j, n_{j/i}) ; 1 \leq j \leq q, i \text{ fixé}\}$$

( $i^{\text{ème}}$  ligne du tableau de contingence en effectifs).

- **Distribution conditionnelle en fréquences de  $X$  sachant  $Y = y_j$  :**

$$\{(x_i, f_{i/j}) ; 1 \leq i \leq p, j \text{ fixé}\}$$

- **Distribution conditionnelle en fréquences de  $Y$  sachant  $X = x_i$  :**

$$\{(y_j, f_{j/i}) ; 1 \leq j \leq q, i \text{ fixé}\}$$

$X/Y = y_j$	effectif	fréquence.
$x_1$	$n_{1/j} = n_{1j}$	$f_{1/j} = \frac{n_{1j}}{n_{\bullet j}}$
$x_2$	$n_{2/j} = n_{2j}$	$f_{2/j} = \frac{n_{2j}}{n_{\bullet j}}$
$\vdots$	$\vdots$	$\vdots$
$x_i$	$n_{i/j} = n_{ij}$	$f_{i/j} = \frac{n_{ij}}{n_{\bullet j}}$
$\vdots$	$\vdots$	$\vdots$
$x_p$	$n_{p/j} = n_{pj}$	$f_{p/j} = \frac{n_{pj}}{n_{\bullet j}}$
Total	$n_{\bullet j} = \sum_{i=1}^p n_{ij}$	1

Dist. cond. eff. et fréq. de  $X$  sachant  $Y = y_j$

$Y/X = x_i$	effectif	fréquence
$y_1$	$n_{1/i} = n_{i1}$	$f_{1/i} = \frac{n_{i1}}{n_{i\bullet}}$
$y_2$	$n_{2/i} = n_{i2}$	$f_{2/i} = \frac{n_{i2}}{n_{i\bullet}}$
$\vdots$	$\vdots$	$\vdots$
$y_j$	$n_{j/i} = n_{ij}$	$f_{j/i} = \frac{n_{ij}}{n_{i\bullet}}$
$\vdots$	$\vdots$	$\vdots$
$y_q$	$n_{q/i} = n_{iq}$	$f_{q/i} = \frac{n_{iq}}{n_{i\bullet}}$
Total	$n_{i\bullet} = \sum_{j=1}^q n_{ij}$	1

Dist. cond .eff. et fréq. de  $Y$  sachant  $X = x_i$

- Il y a  $q$  distributions conditionnelles de  $X$  sachant  $Y = y_j$  (autant que les  $q$  modalités ou classes de  $Y$ )
- Il y a  $p$  distributions conditionnelles de  $Y$  sachant  $X = x_i$  (autant que les  $p$  modalités ou classes de  $X$ )

# Tableau des $q$ distributions conditionnelles de $X$ sachant $Y$

Distribution conditionnelle de  $X$  sachant  $Y = y_j$  dans la colonne  $j$

$X$	$Y$	$y_1$	$y_2$	$\dots$	$y_j$	$\dots$	$y_q$
$x_1$		$f_{1/1}$	$f_{1/2}$	$\dots$	$f_{1/j}$	$\dots$	$f_{1/q}$
$x_2$		$f_{2/1}$	$f_{2/2}$	$\dots$	$f_{2/j}$	$\dots$	$f_{2/q}$
$\vdots$		$\vdots$	$\vdots$		$\vdots$		$\vdots$
$x_i$		$f_{i/1}$	$f_{i/2}$	$\dots$	$f_{i/j}$	$\dots$	$f_{i/q}$
$\vdots$		$\vdots$	$\vdots$		$\vdots$		$\vdots$
$x_p$		$f_{p/1}$	$f_{p/2}$	$\dots$	$f_{p/j}$	$\dots$	$f_{p/q}$
Total		1	1	$\dots$	1	$\dots$	1

# Tableau des $p$ distributions conditionnelles de $Y$ sachant $X$

Distribution conditionnelle de  $Y$  sachant  $X = x_i$  dans la ligne  $i$

$X$	$Y$	$y_1$	$y_2$	$\dots$	$y_j$	$\dots$	$y_q$	Total
$x_1$		$f_{1/1}$	$f_{2/1}$	$\dots$	$f_{j/1}$	$\dots$	$f_{q/1}$	1
$x_2$		$f_{1/2}$	$f_{2/2}$	$\dots$	$f_{j/2}$	$\dots$	$f_{q/2}$	1
$\vdots$		$\vdots$	$\vdots$		$\vdots$		$\vdots$	
$x_i$		$f_{1/i}$	$f_{2/i}$	$\dots$	$f_{j/i}$	$\dots$	$f_{q/i}$	1
$\vdots$		$\vdots$	$\vdots$		$\vdots$		$\vdots$	
$x_p$		$f_{1/p}$	$f_{2/p}$	$\dots$	$f_{j/p}$	$\dots$	$f_{q/p}$	1

## Exemple : Distributions conditionnelles en effectifs de $Y$ sachant $X$

Sexe $X$	Salaire $Y$	[2 ; 26[	[26, 50[	[50, 76[	[76, 100[	Total
Femme		262	31	3	1	297
<b>Homme</b>	<b>Homme</b>	<b>244</b>	<b>49</b>	<b>7</b>	<b>2</b>	<b>302</b>
Total		506	80	10	3	599

- Dist. cond. en effectifs du salaire horaire chez (sachant que) les hommes

Parmi les .... hommes, il y a ..... personnes qui gagnent entre 2 et 26 dollars.

- Sur les .... personnes observées, ... sont des hommes et gagnent entre 2 et 26 dollars.

## Exemple : Distributions conditionnelles en effectifs de $X$ sachant $Y$

Sexe $X$	Salaire $Y$	[2 ; 26[	[26, 50[	[50, 76[	[76, 100[	Total
Femme	<b>262</b>	31	3	1	297	
Homme	<b>244</b>	49	7	2	302	
Total	506	80	10	3	599	

- Dist. cond. en effectifs du sexe sachant que le salaire horaire est compris entre 2 et 26 dollars.

Parmi les ... personnes qui gagnent entre 2 et 26 dollars, il y a ... hommes.

- Sur les ... personnes observées, ... sont des hommes et gagnent entre 2 et 26 dollars.

## Tableau des $q = 4$ distributions conditionnelles en fréquences du sexe $X$ sachant le salaire horaire $Y$

Sexe $X$	Salaire $Y$	[2 ; 26[	[26, 50[	[50, 76[	[76, 100[	Total
Femme	<b>52%</b>	39%	30%	33%	50%	
Homme	<b>48%</b>	61%	70%	67%	50%	
Total	100%	100%	100%	100%	100%	100%

- Dist. cond. en fréquences du sexe sachant que le salaire horaire est compris entre 2 et 26 dollars.
- Parmi les ... personnes qui gagnent entre 2 et 26 dollars, il y en a ...% hommes.
- Sur les .... personnes observées, ....% sont des hommes et gagnent entre 2 et 26 dollars

## Tableau des $p = 3$ distributions conditionnelles en fréquences du salaire horaire $Y$ selon le sexe $X$

Sexe $X$	Salaire $Y$	[2 ; 26[	[26, 50[	[50, 76[	[76, 100[	Total
Femme		88%	10%	1%	1%	100%
<b>Homme</b>		<b>81%</b>	<b>16%</b>	<b>2%</b>	<b>1%</b>	100%
dist. marg. de $Y$		85%	13%	2%	0%	100%

- Dist. cond. en fréquences de l'âge sachant la catégorie de personnel.
- Parmi les ... hommes, il y a ...% des personnes qui gagnent entre 2 et 26 dollars.
- Sur les ... personnes observées, ...% sont des hommes et gagnent entre 2 et 26 dollars

# Moyennes, variances marginales et conditionnelles

- **UNIQUEMENT** pour variables quantitatives.
- Données brutes : calculs similaires à ceux effectués en statistique univariée après extraction des individus d'intérêt.
- Données groupées : à partir des tableaux de contingence.

# Moyennes et variances marginales

- Distribution marginale de  $X$  en effectifs/fréquences

$$\{(x_i, n_{i\bullet}) ; 1 \leq i \leq p\} \quad \{(x_i, f_{i\bullet}) ; 1 \leq i \leq p\}$$

- Distribution marginale de  $Y$  en effectifs/fréquences

$$\{(y_j, n_{\bullet j}) ; 1 \leq j \leq q\} \quad \{(y_j, f_{\bullet j}) ; 1 \leq j \leq q\}$$

- Moyennes marginales  $\bar{x}$  et  $\bar{y}$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^p n_{i\bullet} x_i = \sum_{i=1}^p f_{i\bullet} x_i$$

$$\bar{y} = \frac{1}{n} \sum_{j=1}^q n_{\bullet j} y_j = \sum_{j=1}^q f_{\bullet j} y_j$$

# Moyennes marginales : AGE et SALAIRE

```
> print(TabContEf)
> addmargins(TabContEf)
      SALAIRE
Age      (1.9,26.2] (26.2,50.5] (50.5,74.8] (74.8,99.1] Sum
(15.9,32]        180         11          0        1 192
(32,48]         156         28          5        0 189
(48,64]         144         40          4        1 189
(64,80.1]       26          1          1        1 29
Sum            506         80          10        3 599
> margin.table(TabContEf,1)
Age
(15.9,32]  (32,48]  (48,64]  (64,80.1]
 192       189      189       29
> margin.table(TabContEf,2)
SALAIRE
(1.9,26.2] (26.2,50.5] (50.5,74.8] (74.8,99.1]
 506         80         10         3
## A comparer avec :
> mean(AGE)
[1] 41.84975
> mean(SAL_HOR)
[1] 17.89835
```

- Variances marginales  $\sigma_x^2$  et  $\sigma_y^2$

$$V(x) = \sigma_x^2 = \frac{1}{n} \sum_{i=1}^p n_{i\bullet} (x_i - \bar{x})^2 = \sum_{i=1}^p f_{i\bullet} (x_i - \bar{x})^2$$

$$V(y) = \sigma_y^2 = \frac{1}{n} \sum_{j=1}^q n_{\bullet j} (y_j - \bar{y})^2 = \sum_{j=1}^q f_{\bullet j} (y_j - \bar{y})^2$$

- Soit aussi

$$\sigma_x^2 = \frac{1}{n} \sum_{i=1}^p n_{i\bullet} x_i^2 - (\bar{x})^2 = \sum_{i=1}^p f_{i\bullet} x_i^2 - (\bar{x})^2$$

$$\sigma_y^2 = \frac{1}{n} \sum_{j=1}^q n_{\bullet j} y_j^2 - (\bar{y})^2 = \sum_{j=1}^q f_{\bullet j} y_j^2 - (\bar{y})^2$$

# Variances marginales : AGE et SALAIRE

```

> print(TabContEf)
> addmargins(TabContEf)
      SALAIRE
Age          (1.9,26.2] (26.2,50.5] (50.5,74.8] (74.8,99.1] Sum
(15.9,32]        180         11          0       1 192
(32,48]         156         28          5       0 189
(48,64]         144         40          4       1 189
(64,80.1]        26          1          1       1 29
Sum            506         80          10      3 599
> margin.table(TabContEf,1)
Age
(15.9,32]  (32,48]  (48,64]  (64,80.1]
 192       189       189       29
> margin.table(TabContEf,2)
SALAIRE
(1.9,26.2] (26.2,50.5] (50.5,74.8] (74.8,99.1]
 506         80         10         3
## A comparer avec :
> var(AGE)
[1] 199.275
> var(SAL_HOR)
[1] 127.2247

```

# Moyennes et variances conditionnelles

Pour  $j = 1, \dots, q$

- Dist. cond. de  $X$  en effectifs/fréquences sachant que  $Y = y_j$

$$\{(x_i, n_{i/j}) ; 1 \leq i \leq p\} \quad \{(x_i, f_{i/j}) ; 1 \leq i \leq p\}$$

avec

$$n_{i/j} = n_{ij} \quad \text{et} \quad f_{i/j} = \frac{n_{ij}}{n_{\bullet j}}$$

- Moyenne conditionnelle de  $X$  sachant que  $Y = y_j$  :  $\bar{x}_{/j}$

$$\bar{x}_{/j} = \bar{x}_{/Y=y_j} = \frac{1}{n_{\bullet j}} \sum_{i=1}^p n_{i/j} x_i = \frac{1}{n_{\bullet j}} \sum_{i=1}^p n_{ij} x_i = \sum_{i=1}^p f_{i/j} x_i ;$$

- Variance conditionnelle de  $X$  sachant que  $Y = y_j$  :  $\sigma_{x/j}^2$

$$\sigma_{x/j}^2 = V(x_{/Y=y_j}) = \frac{1}{n_{\bullet j}} \sum_{i=1}^p n_{i/j} (x_i - \bar{x}_{/j})^2 = \sum_{i=1}^p f_{i/j} (x_i - \bar{x}_{/j})^2 .$$

Pour  $i = 1, \dots, p$

- Dist. cond. de  $Y$  en effectifs/fréquences sachant que  $X = x_i$

$$\{(y_j, n_{j/i}) ; 1 \leq j \leq q\} \quad \{(y_j, f_{j/i}) ; 1 \leq j \leq q\}$$

avec

$$n_{j/i} = n_{ij} \quad \text{et} \quad f_{j/i} = \frac{n_{ij}}{n_{i\bullet}}$$

- Moyenne conditionnelle de  $Y$  sachant que  $X = x_i$  :  $\bar{y}_{/i}$

$$\bar{y}_{/i} = \bar{y}_{/X=x_i} = \frac{1}{n_{i\bullet}} \sum_{j=1}^q n_{j/i} y_j = \frac{1}{n_{i\bullet}} \sum_{j=1}^q n_{ij} y_j = \sum_{j=1}^q f_{j/i} y_j ;$$

- Variance conditionnelle de  $Y$  sachant que  $X = x_i$  :  $\sigma_{y/i}^2$

$$\sigma_{y/i}^2 = V(y_{/X=x_i}) = \frac{1}{n_{i\bullet}} \sum_{j=1}^q n_{j/i} (y_j - \bar{y}_{/i})^2 = \sum_{j=1}^q f_{j/i} (y_j - \bar{y}_{/i})^2 .$$

## Autre écriture de la variance conditionnelle

$$\begin{aligned}
 \sigma_{x/j}^2 &= \frac{1}{n_{\bullet j}} \sum_{i=1}^p n_{i/j} (x_i - \bar{x}_{/j})^2 \\
 &= \frac{1}{n_{\bullet j}} \sum_{i=1}^p n_{ij} x_i^2 - (\bar{x}_{/j})^2 = \sum_{i=1}^p f_{i/j} x_i^2 - (\bar{x}_{/j})^2 \\
 \sigma_{y/i}^2 &= \frac{1}{n_{i\bullet}} \sum_{j=1}^q n_{j/i} (y_j - \bar{y}_{/i})^2 \\
 &= \frac{1}{n_{i\bullet}} \sum_{j=1}^q n_{ij} y_j^2 - (\bar{y}_{/i})^2 = \sum_{j=1}^q f_{j/i} y_j^2 - (\bar{y}_{/i})^2
 \end{aligned}$$

# Moyennes et variances conditionnelles du salaire par âge

```
> round(tapply(SAL_HOR, Age, mean),2)
(15.9,32]  (32,48]  (48,64] (64,80.1]
    14.14     18.62    20.83    18.97
> round(tapply(SAL_HOR, Age, var),2)
(15.9,32]  (32,48]  (48,64] (64,80.1]
    80.15    127.34   140.10   215.17
> tapply(SAL_HOR,Age,summary)
$(15.9,32]'
  Min. 1st Qu. Median   Mean 3rd Qu.   Max.
  2.25    9.00  12.00  14.14  16.34  90.00
$(32,48]'
  Min. 1st Qu. Median   Mean 3rd Qu.   Max.
  2.00   10.75  15.00  18.62  22.11  74.00
$(48,64]'
  Min. 1st Qu. Median   Mean 3rd Qu.   Max.
  4.00   13.00  19.00  20.83  25.72  99.00
$(64,80.1]'
  Min. 1st Qu. Median   Mean 3rd Qu.   Max.
  7.65   12.00  16.00  18.97  18.00  75.00
```

# Moyennes et variances conditionnelles de l'âge par tranche de salaire

```
> round(tapply(AGE, SALAIRE, mean),2)
(1.9,26.2] (26.2,50.5] (50.5,74.8] (74.8,99.1]
        40.80      47.06      50.30      52.00
> round(tapply(AGE, SALAIRE, var),2)
(1.9,26.2] (26.2,50.5] (50.5,74.8] (74.8,99.1]
       205.08     123.86     131.12     441.00
> tapply(AGE,SALAIRE,summary)
$(`(1.9,26.2]`)
   Min. 1st Qu. Median Mean 3rd Qu. Max.
   16.0    28.0   40.0  40.8    52.0   80.0
$(`(26.2,50.5]`)
   Min. 1st Qu. Median Mean 3rd Qu. Max.
   25.00   38.75   49.00  47.06   56.25  70.00
$(`(`50.5,74.8]`)
   Min. 1st Qu. Median Mean 3rd Qu. Max.
   37.00   40.25   48.50  50.30   58.75  70.00
$(`(`74.8,99.1]`)
   Min. 1st Qu. Median Mean 3rd Qu. Max.
   28.0    44.5    61.0   52.0    64.0   67.0
```

## Lien entre moyennes marginales et conditionnelles

⇒ On peut retrouver la moyenne marginale (générale) en calculant la moyenne pondérée des moyennes conditionnelles.

$$\bar{x} = \frac{1}{n} \sum_{j=1}^q n_{\bullet j} \bar{x}_{/j} = \sum_{j=1}^q f_{\bullet j} \bar{x}_{/j}$$
$$\bar{y} = \frac{1}{n} \sum_{i=1}^p n_{i \bullet} \bar{y}_{/i} = \sum_{i=1}^p f_{i \bullet} \bar{y}_{/i}$$

## Décomposition de la variance

⇒ On peut pas retrouver la variance marginale à partir des variances conditionnelles.

Variance marginale = variance des moyennes conditionnelles + moyenne des variances conditionnelles.

$$\begin{aligned}\sigma_{\mathbf{x}}^2 &= \frac{1}{n} \sum_{j=1}^q n_{\bullet j} (\bar{\mathbf{x}}_{/\mathbf{j}} - \bar{\mathbf{x}})^2 + \frac{1}{n} \sum_{j=1}^q n_{\bullet j} \sigma_{\mathbf{x}/\mathbf{j}}^2 \\ \sigma_{\mathbf{y}}^2 &= \frac{1}{n} \sum_{i=1}^p n_{i\bullet} (\bar{\mathbf{y}}_{/\mathbf{i}} - \bar{\mathbf{y}})^2 + \frac{1}{n} \sum_{i=1}^p n_{i\bullet} \sigma_{\mathbf{y}/\mathbf{i}}^2\end{aligned}$$

## Remarque

- On peut calculer les moyennes et les variances conditionnelles d'une variable quantitative sachant les modalités d'une variable qualitative.
- Mais la réciproque est fausse ! Evident !

## Exemple :

SEXE X	Salaire Y	[2 ;26[	[26,50[	[50,76[	[76,100[	Total
Femme	88%	10%	1%	1%	100%	
Homme	81%	16%	2%	1%	100%	
dist. marg. de Y	85%	13%	2%	0%	100%	

- Le salaire horaire moyen de l'ensemble des personnes observés est de 17,9 dollars  $\Rightarrow \bar{y} = 17,9$
- Le salaire horaire moyen des femmes A est de 16,6 dollars  
 $\Rightarrow \bar{y}_{/A} = 16,6$
- Le salaire horaire moyen des hommes B est de 19,17 dollars  
 $\Rightarrow \bar{y}_{/B} = 19,17$
- $17,9 = \bar{y} = \sum_{i=1}^p f_{i\bullet} \bar{y}_{/i} = 0,4959 * 16,6 + 0,5041 * 19,17$   
 $\implies$  voir Slide 52.

## Exemple :

SEXE X	Salaire Y	[2 ;26[	[26,50[	[50,76[	[76,100[	Total
Femme	88%	10%	1%	1%	100%	
Homme	81%	16%	2%	1%	100%	
dist. marg. de Y	85%	13%	2%	0%	100%	

- La variance marginale du salaire horaire est  $\sigma_y^2 = 127,22$ .
- La variance du salaire horaire des femmes est  $\sigma_{y/F}^2 = 105,84$ .
- La variance du salaire horaire des hommes est  $\sigma_{y/M}^2 = 145,39$ .

## Moyennes et variances conditionnelles du salaire horaire par sexe

```
> round(tapply(SAL_HOR, SEXE, mean),2)
      F      M
16.60 19.17
```

```
> round(tapply(SAL_HOR, SEXE, var),2)
      F      M
105.84 145.39
```

```
> tapply(SAL_HOR,SEXE,summary)
$F
   Min. 1st Qu. Median     Mean 3rd Qu.    Max.
   2.25    10.00   14.00   16.60   20.00   90.00
```

```
$M
   Min. 1st Qu. Median     Mean 3rd Qu.    Max.
   2.00    11.00   15.70   19.17   23.04   99.00
```